

刘迪乘

(+86) 185-7049-9315 · 2312810@mail.nankai.edu.cn · 南开大学 · GitHub <https://github.com/July-h5kf3>

教育背景

南开大学, 计算机科学与技术, 工学学士

2023.9 – 2027.6

GPA: 3.70, 排名 33/169 (前 20%), 创新奖学金

相关课程: 高等数学、概率论与数理统计、算法导论、并行程序设计、人工智能导论、高级语言程序设计 (C++)、Python 高阶程序设计 (均为 A)

语言能力: 英语 (CET-6, 520)

技术能力

- 编程语言: Python, C++
- 人工智能: NLP, LLM 与 VLM 的轻量化、训练与推理加速
- 高性能计算: 并行计算, GPU 加速 (CUDA, HIP), 算子开发与算子调优
- 工程优化: 模型训练流程优化, 推理性能优化, 训练效率分析与瓶颈定位

经历

天津市视觉计算与智能感知重点实验室 (VCIP), 实习生

2025.12-现在

• VLM 模型 Real Quant 推理 Pipeline 搭建

此前组内量化评测主要依赖 **fake quant** (伪量化): 仅在 FP16 计算图中插入量化/反量化节点来模拟低比特精度, 权重与计算实际仍为高精度。这既无法真实反映各量化方法的实际加速比, 又因额外的量化/反量化算子引入计算与访存开销, 导致“测出来的速度”与真实部署严重背离。为此面向 VLM 模型搭建量化推理 Baseline 与 **real quant pipeline**, 支持主流多模态量化方法的真实低比特权重导出与格式转换, 并适配 vLLM 与 TensorRT-LLM 推理框架, 覆盖 W4A16、W4A8、W3A16 等主流精度配置; 完成精度回归测试、吞吐评测与自动化 benchmark, 以真实量化权重与低比特算子替代伪量化/仿真路径, 消除冗余量化/反量化开销并降低显存带宽占用。在 RTX 4090 上, Qwen2.5-VL-7B 量化推理较 fake quant 加速约 10 倍。

NKAI 竞赛社, 社员

2025.7-现在

• 百度 2026 CTI 生成式广告排序推理性能优化大赛 | 队长

榜单第 3 2026.6

百度举办, 聚焦生成式广告排序大模型的推理性能优化 (超长行为序列、复杂注意力与量化精度等挑战), 参与人数超 1300。

对 RepEncoder、Attention、MoE 各组件进行详细 profiling, 针对性优化: RepEncoder 侧发现瓶颈并非稠密计算, 而是逐 slot 循环产生的大量小 kernel, 以及 Embedding、segment reduce、cat 与 LayerNorm 之间反复写入中间张量, 因此将其判断为以 kernel launch 与显存访问为主的瓶颈, 并进行 slot 粒度稀疏特征 EmbeddingBag/segment reduce/cat/LayerNorm 融合以减少 launch 与中间写回; Attention 侧发现 baseline 中 attention 占约 60% 耗时, 明显高于 QKV 投影本身, 说明主要瓶颈不在单个 Linear, 而在多用户行为序列拼接后的 dense attention 路径, 因此结合经验使用 xFormers BlockDiagonal Causal Attention 与 bias cache, 避免了长序列下 dense mask 的构建; MoE 的主要瓶颈在于频繁的 kernel launch, 因此进行 token/expert 粒度融合 Gate TopK2 + Align 路由整理、逐 token 行级融合 MoE Sum + Residual(+LayerNorm) epilogue, 并将 for-loop MoE 改写为 fused MoE, 以使用高效的 fused MoE GEMM。最后使用 AWQ 对模型权重进行量化, 将推理耗时由 Baseline 230 s 降低至 20 s。

• 2025 腾讯广告算法大赛 (TAAC) | 队长

初赛前 20% 2025.8

腾讯广告主办的工业级算法赛事, 面向真实广告推荐场景, 需在大规模用户行为数据上构建生成式推荐/检索模型并完成离线评测, 超 3000 支队伍参加。

主要负责模型工程化与训练/推理效率优化。将特征构造、负样本组织等数据处理逻辑下沉至 Dataset, 充分利用 DataLoader 多线程并行, 并对数据处理流水线进行并行化重构; 针对大规模负样本下的 InfoBCE Loss 计算, 设计分块矩阵乘法算子, 降低峰值显存占用并提升训练吞吐, 将训练耗时由 2 h/epoch 降低至 30 min/epoch。推理阶段使用 PyTorch 矩阵乘法替代 FAISS 检索操作, 并通过 batch 化计算规避大矩阵一次性计算导致的显存不足, 将推理耗时由 15–20 min 降低至 30 s, 为团队模型 Scaling 提供工程基础。

• DataCon 2025 大数据安全分析竞赛——口令安全赛道 | 队长

榜单第 1, 综合答辩第 2 2025.11

面向大数据安全分析的国内权威赛事, 口令安全赛道聚焦口令猜测/破解算法的效果与效率, 需在真实口令数据上比拼候选生成与命中能力。

针对先进口令猜测算法多停留在实验室 Demo、效率弱于 Hashcat 的问题，负责将概率猜测算法并行化并融合进 Hashcat，开发 Prob-Hashcat，使 PCFG、Markov 等算法利用 GPU 加速；候选口令生成吞吐由 CPU 约 1 亿 samples/s 提升至约 800 亿 samples/s，达到 Hashcat 暴力破解约 1/4 的生成效率。

- 2025 腾讯游戏算法大赛 (TGAC) ——3D 运动重建赛道 | 队长 榜单第 2，创新性第 4 2025.12 腾讯游戏主办的算法赛事，3D 运动重建赛道要求从视频中重建人体三维运动，服务游戏动作捕捉与数字人等场景。

负责 GVHMR、TRAM 等 3D 运动重建模型在较新动作数据集上的训练与推理优化，完成数据格式适配、关键点/相机参数对齐、异常样本清洗与训练配置调整，提升新数据分布下的训练稳定性；推理阶段优化预处理、模型调用与结果后处理流程，提升多视频批量评测效率。

项目作品

- CS336: 从零搭建大语言模型训练与推理流程系统实现大模型从数据到推理的完整 pipeline：包括语料清洗、BPE Tokenizer、Transformer Decoder、AdamW、学习率调度、checkpoint、生成式推理与基础评测；搭建后训练流程，在 Math 数据集上对 Qwen2.5 1.5B 分别使用 SFT、Expert Iteration 与 GRPO 强化学习，提升带思维链的数学推理能力。在课程基础要求上扩展训练系统能力，实现数据并行、张量并行、流水线并行、序列并行组成的 4D 并行训练，并对 DDP 做通信优化：通过异步通信重叠反向传播计算与梯度同步，按参数梯度分桶执行 reduce 以掩盖通信开销。实现 FlashAttention 前向与后向 Triton Kernel，优化 shared memory/block tiling 与在线 softmax 计算，性能达到 2025 课程 leaderboard Top10 同等水平 (25 ms on H100)；结合同步训练、通信优化与 FlashAttention Kernel，在 8 卡 V100 上取得约 3 倍训练加速。课程外结合研究兴趣搭建 PTQ 流程，支持 GPTQ 与 AWQ，并实现量化推理链路及 8bit 配套运算算子；将课程开发的 Triton 算子合并至 Triton-Puzzles-Lite (710+ stars)，为 Triton 入门者提供基于 block pointer 抽象的参考答案。

竞赛获奖

- NOIP2021(全国信息学奥林匹克竞赛) 湖南省二等奖, 2021, 11 月
- 2024 年全国普通高校大学生数学竞赛天津市二等奖, 2024 7 月
- 第十七届全国大学生信息安全竞赛全国一等奖, 2024 年 8 月
- 2024 年全国大学生数学建模竞赛天津市二等奖, 2024 11 月
- 第八届 CCF-TCARCH 2025 计算机体系结构挑战赛全国三等奖 2025 9 月
- DataCon2025 大数据安全分析竞赛全国一等奖, 2025 11 月
- 第十届全国密码技术竞赛全国三等奖, 2025 11 月
- 2025 年全国大学生数学建模竞赛天津市一等奖, 2025 11 月
- 2025 腾讯游戏算法大赛 (TGAC) 第四名, 2025 12 月